DATA CARD DATASET

Indonesia E-Commerce Sales & Shipping 2023–2025

Untuk Tugas Kelompok 1 – Pengantar Big Data

Fondasi Penelitian dan Persetujuan Dataset

1. Identitas Dataset

Nama dataset	Indonesia E-Commerce Sales & Shipping 2023–2025
Nama file yang digunakan	all_months_clean.csv
Penerbit/pembuat	BakiTacos
Platform sumber	Kaggle
URL	https://www.kaggle.com/datasets/bakitacos/indonesia-e-commerce-sales-and-shipping-20232025
Lisensi	CC BY-SA 4.0
Jenis data	Data tabular transaksi e-commerce
Periode dataset	Desember 2023 – November 2025
Tanggal akses	6 September 2026
Versi	CLEAN version; halaman Kaggle tidak mencantumkan nomor versi khusus
Jumlah baris	20.848 transaksi
Jumlah kolom	19 atribut

2. Ringkasan Dataset

Dataset berisi data transaksi e-commerce Indonesia selama 24 bulan, dari Desember 2023 hingga November 2025. Setiap baris merepresentasikan satu pesanan yang telah diagregasi dari level item. Dataset mencakup informasi jumlah barang, berat pesanan, diskon, status pesanan, alasan pembatalan, opsi pengiriman, metode pembayaran, wilayah tujuan, biaya pengiriman, total pembayaran, serta waktu pembuatan pesanan. Menurut dokumentasi Kaggle, order ID telah dianonimkan dan dataset tidak memuat data pribadi pelanggan.

3. Struktur dan Atribut Dataset

Atribut	Tipe	Deskripsi
order_id	object	ID unik/anonymized untuk setiap pesanan.
total_qty	int64	Jumlah total barang dalam satu pesanan.
total_weight_gr	int64	Total berat pesanan dalam gram.
total_returned_qty	int64	Jumlah barang yang dikembalikan.
Total Diskon	int64	Nilai total diskon pada pesanan.
product_categories	object	Kategori produk yang terdapat dalam pesanan.
num_product_categories	int64	Jumlah kategori produk dalam satu pesanan.
Status Pesanan	object	Status akhir/proses pesanan, misalnya Selesai atau Batal.
Alasan Pembatalan	object	Alasan pembatalan pesanan jika pesanan dibatalkan.
Opsi Pengiriman	object	Layanan atau opsi pengiriman yang dipilih.
Metode Pembayaran	object	Metode pembayaran yang digunakan pelanggan.
Kota/Kabupaten	object	Kota/kabupaten tujuan pengiriman.
Provinsi	object	Provinsi tujuan pengiriman.
Ongkos Kirim Dibayar oleh Pembeli	int64	Nilai ongkos kirim yang dibayar oleh pembeli.
Estimasi Potongan Biaya Pengiriman	int64	Estimasi subsidi/potongan biaya pengiriman.
Total Pembayaran	int64	Total nilai pembayaran untuk pesanan.
Perkiraan Ongkos Kirim	int64	Perkiraan biaya pengiriman.

Waktu Pesanan Dibuat	object → datetime	Tanggal dan waktu pesanan dibuat; sebagian nilai kosong pada file yang digunakan.
source_file	object	Nama file sumber bulanan dari proses penggabungan dataset.

4. Kualitas Data

File all_months_clean.csv yang digunakan memiliki 20,848 baris dan 19 kolom. Sebanyak 1,980 baris (9.50%) tidak memiliki nilai pada atribut Waktu Pesanan Dibuat. Atribut Alasan Pembatalan memiliki 18,018 nilai kosong (86.43%), yang secara substantif wajar karena atribut tersebut terutama relevan untuk pesanan yang dibatalkan.

Untuk tanggal yang tersedia, rentang waktunya adalah 01 December 2023 sampai 30 November 2025. Tidak ditemukan nilai tanggal yang tidak dapat diparse setelah konversi ke format datetime pada nilai yang tidak kosong.

5. Distribusi Status Pesanan

Status utama terdiri dari 17,768 pesanan Selesai dan 2,830 pesanan Batal. Selain itu terdapat beberapa status proses pengiriman/pasca-penerimaan. Untuk analisis klasifikasi, status perlu didefinisikan secara konsisten; misalnya penelitian dapat memfokuskan target pada Batal vs Selesai dan memperlakukan status antara sebagai data yang perlu ditinjau atau dikeluarkan sesuai desain penelitian.

6. Target Analisis yang Diusulkan

Target utama yang diusulkan untuk analisis lanjutan adalah Status Pesanan, khususnya klasifikasi Batal vs Selesai. Variabel prediktor yang dapat dipertimbangkan antara lain total_qty, total_weight_gr, Total Diskon, product_categories, Opsi Pengiriman, Metode Pembayaran, wilayah, biaya pengiriman, dan Total Pembayaran. Pemilihan fitur harus memperhatikan potensi data leakage, terutama atribut yang baru diketahui setelah status pesanan terjadi.

7. Potensi Bias dan Keterbatasan

- Dataset merupakan data publik sekunder dari satu sumber/pengelola data, sehingga belum tentu merepresentasikan seluruh transaksi e-commerce di Indonesia.
- Distribusi wilayah dan kategori produk tidak merata; transaksi terkonsentrasi pada beberapa provinsi dan kategori tertentu.
- Terdapat ketidakseimbangan kelas antara pesanan Selesai dan Batal, sehingga analisis klasifikasi tidak sebaiknya hanya menggunakan accuracy.
- Sebagian Waktu Pesanan Dibuat kosong sehingga analisis berbasis waktu perlu menangani missing value.
- Beberapa atribut status berisi status proses yang berbeda-beda, sehingga perlu standardisasi label sebelum analisis.
- Kategori produk merupakan pengelompokan kategori dan bukan nama produk individual; hasil analisis tidak dapat langsung digeneralisasi ke seluruh jenis produk.
- Data bersifat agregat pada tingkat pesanan dan tidak menyediakan identitas pelanggan, sehingga analisis perilaku pelanggan individual tidak dapat dilakukan.

8. Privasi dan Sensitivitas Data

Menurut dokumentasi sumber Kaggle, dataset tidak mengandung Personally Identifiable Information (PII), order ID telah dianonimkan, dan nama produk dihapus pada versi RAW_PUBLIC. Walaupun demikian, data wilayah kota/kabupaten dan pola transaksi tetap perlu digunakan hanya untuk tujuan analisis yang relevan dan tidak digabungkan dengan sumber lain untuk mencoba mengidentifikasi individu.

9. Lisensi dan Redistribusi

Dataset sumber menggunakan lisensi Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0

10. Referensi Sumber

BakiTacos. (2025). Indonesia E-Commerce Sales & Shipping 2023–2025 [Data set]. Kaggle.

URL: https://www.kaggle.com/datasets/bakitacos/indonesia-e-commerce-sales-and-shipping-20232025

Tanggal akses: 6 September 2026.