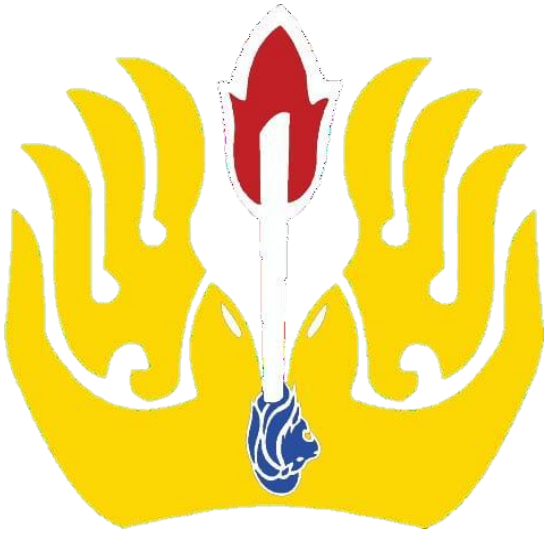
PROPOSAL TUGAS KELOMPOK

“ Analisis Pola Penjualan, Pembatalan Pesanan, dan Biaya Pengiriman pada E-Commerce Indonesia Periode 2023–2025 “

Disusun untuk Memenuhi Tugas Mata Kuliah Pengantar Big Data

Dosen Pengampu : Nono Heryana, S.Kom., M.Kom.



Disusun oleh:

Keysa Avmalia (2410631250013)

Zahwa Lamini Arsyi Anjuni (2410631250114)

(Kelompok 5)

Kelas 5C

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS ILMU KOMPUTER

UNIVERSITAS SINGAPERBANGSA KARAWANG

TAHUN 2026

BAB I
PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi digital telah mendorong pertumbuhan perdagangan elektronik atau e-commerce di Indonesia. Aktivitas transaksi melalui platform digital menghasilkan data dalam jumlah besar yang dapat dimanfaatkan untuk memperoleh informasi mengenai pola penjualan, perilaku transaksi, metode pembayaran, serta proses pengiriman.

Dataset **Indonesia E-Commerce Sales & Shipping 2023–2025** menyediakan data transaksi e-commerce Indonesia selama periode Desember 2023 hingga November 2025. Dataset tersebut memuat informasi mengenai jumlah barang, berat pesanan, diskon, kategori produk, status pesanan, alasan pembatalan, metode pembayaran, opsi pengiriman, wilayah tujuan, biaya pengiriman, total pembayaran, dan waktu pemesanan.

Keberagaman atribut tersebut memungkinkan dilakukan analisis untuk mengetahui pola transaksi dan karakteristik pesanan e-commerce. Salah satu aspek yang penting untuk dianalisis adalah **pembatalan pesanan**, karena pembatalan dapat memengaruhi efektivitas proses transaksi dan pengiriman. Selain itu, biaya pengiriman juga dapat dianalisis berdasarkan wilayah dan karakteristik transaksi untuk memperoleh gambaran mengenai distribusi biaya logistik.

Oleh karena itu, penelitian ini dilakukan untuk menganalisis pola penjualan, pembatalan pesanan, metode pembayaran, serta biaya pengiriman pada transaksi e-commerce di Indonesia selama periode 2023–2025.

1.2 Identifikasi Masalah

Berdasarkan latar belakang tersebut, permasalahan yang akan dikaji adalah:

1. Belum diketahui bagaimana pola jumlah transaksi e-commerce selama periode 2023–2025.
2. Belum diketahui kategori produk yang memiliki jumlah transaksi dan nilai pembayaran tertinggi.
3. Belum diketahui pola penggunaan metode pembayaran dalam transaksi.
4. Belum diketahui karakteristik dan pola pembatalan pesanan.
5. Belum diketahui bagaimana biaya pengiriman tersebar berdasarkan wilayah dan karakteristik transaksi.

1.3 Tujuan

Tujuan Umum

Menganalisis pola transaksi e-commerce di Indonesia selama periode 2023–2025 berdasarkan karakteristik penjualan, pembatalan pesanan, pembayaran, dan pengiriman.

Tujuan Khusus

1. Mengetahui perkembangan transaksi berdasarkan waktu.
2. Mengidentifikasi kategori produk dengan transaksi dan pembayaran tertinggi.
3. Mengetahui distribusi penggunaan metode pembayaran.
4. Menganalisis pola pembatalan pesanan.
5. Menganalisis karakteristik biaya pengiriman berdasarkan wilayah dan transaksi.

1.4 Pertanyaan Analitik

Penelitian ini memiliki beberapa pertanyaan analitik:

1. Bagaimana perkembangan jumlah transaksi e-commerce dari Desember 2023 hingga November 2025?
2. Kategori produk apa yang memiliki jumlah transaksi dan total pembayaran tertinggi?
3. Bagaimana distribusi transaksi berdasarkan metode pembayaran?
4. Bagaimana pola pembatalan pesanan berdasarkan waktu, kategori produk, dan metode pembayaran?
5. Bagaimana karakteristik biaya pengiriman berdasarkan wilayah tujuan dan nilai transaksi?

1.5 Unit Analisis

Unit analisis dalam penelitian ini adalah transaksi/pesanan e-commerce. Setiap baris pada dataset all_months_clean.csv merepresentasikan satu pesanan yang memiliki informasi mengenai jumlah barang, berat pesanan, kategori produk, status pesanan, metode pembayaran, opsi pengiriman, wilayah tujuan, biaya pengiriman, total pembayaran, dan waktu pemesanan.

1.6 Pengguna Hasil

Hasil penelitian ini dapat digunakan oleh pelaku bisnis e-commerce, penjual/merchant, dan pihak yang menangani operasional serta logistik untuk memahami pola transaksi, pembatalan pesanan, metode pembayaran, dan biaya pengiriman. Selain itu, hasil penelitian dapat digunakan oleh peneliti atau mahasiswa sebagai referensi untuk analisis data e-commerce dan pengembangan penelitian lebih lanjut.

BAB II

DATASET PUBLIK

2.1 Identitas Dataset

Atribut	Keterangan
Nama dataset	Indonesia E-Commerce Sales & Shipping 2023–2025
Penerbit/Pengunggah	Akun Kaggle "bakitacos"
URL	https://www.kaggle.com/datasets/bakitacos/indonesia-e-commerce-sales-and-shipping-20232025
DOI	*Tidak mencantumkan DOI*
Lisensi	*CC BY-SA 4.0*
Versi	*CLEAN version; halaman Kaggle tidak mencantumkan nomor versi khusus*
Tanggal akses	*6 September 2026*
Periode data	Desember 2023 – November 2025 (24 bulan)
Jumlah baris	≥ 20.000 baris (level pesanan)
Format berkas	Dua varian CSV: CLEAN (sudah distandarkan, siap untuk pemodelan) dan RAW_PUBLIC (mendekati struktur asli, lightly processed)
Berkas yang digunakan	all_months_clean.csv (varian CLEAN, gabungan seluruh bulan periode Des 2023–Nov 2025)

2.2 Atribut Utama dan target

Berdasarkan deskripsi resmi pada halaman dataset, atribut utama yang tersedia meliputi:

1. Metadata pesanan: waktu order, status (selesai/dibatalkan), dan alasan pembatalan.
2. Total kuantitas barang dan berat total kiriman per pesanan.
3. Komponen biaya pengiriman: ongkir yang dibayar pembeli, ongkir estimasi, dan besaran subsidi ongkir.
4. Informasi metode pembayaran yang digunakan.
5. Pengelompokan kategori produk (hasil klasifikasi otomatis oleh penerbit).
6. Provinsi dan kota tujuan pengiriman (telah dianonimkan ke level geografis yang aman).

Target/label yang berpotensi digunakan untuk metode lanjutan (klasifikasi) adalah status pesanan (selesai vs. dibatalkan). Penerbit menyatakan seluruh order ID telah dianonimkan dan dataset tidak memuat data pribadi pelanggan (no PII).

2.3 Alasan Pemilihan Dataset

1. Relevan dengan konteks big data komersial Indonesia dan mencakup periode cukup panjang (24 bulan) untuk analisis tren waktu.
2. Ukuran data (≥20.000 baris) memadai untuk latihan analisis deskriptif, visualisasi, hingga pemodelan klasifikasi dasar.
3. Tersedia dalam dua versi (RAW_PUBLIC dan CLEAN) sehingga kelompok dapat mendemonstrasikan proses data cleaning sekaligus memiliki versi siap pakai untuk pemodelan.
4. Data telah dianonimkan oleh penerbit sehingga risiko privasi relatif rendah dibanding dataset transaksi mentah.
5. Dataset ini sudah pernah dipakai pada penelitian akademik lain mengenai prediksi pembatalan pesanan (lihat Tinjauan Pustaka), yang mengindikasikan dataset cukup layak untuk pertanyaan analitik sejenis.

2.4 Potensi Bias

1. Dataset kemungkinan berasal dari satu platform atau sekumpulan penjual tertentu, sehingga pola yang ditemukan belum tentu merepresentasikan seluruh industri e-commerce nasional.
2. Agregasi dari level-item ke level-pesanan oleh penerbit dapat mengaburkan variasi pada tingkat produk individual.
3. Kategori produk berasal dari klasifikasi otomatis yang berpotensi memiliki kesalahan label (label noise).
4. Distribusi geografis kemungkinan tidak merata (bias ke wilayah dengan penetrasi e-commerce tinggi, mis. Jawa), sehingga model dapat bias terhadap wilayah tersebut.
5. Kelas target pembatalan pesanan berpotensi tidak seimbang (imbalanced); penelitian lain yang menggunakan dataset serupa menerapkan teknik penyeimbangan kelas (SMOTE), yang mengindikasikan potensi ketimpangan ini perlu diantisipasi juga oleh kelompok.

2.5 Sensitivitas Data

Berdasarkan deskripsi penerbit, dataset tidak memuat data pribadi pelanggan (no PII) dan order ID telah dianonimkan. Meskipun demikian, kombinasi atribut waktu, kota tujuan, dan kategori produk pada volume kecil berpotensi menimbulkan risiko kuasi-identifikasi (quasi-identification). Untuk mengantisipasi hal ini, kelompok akan: (1) tidak menggabungkan dataset dengan sumber data eksternal yang dapat memfasilitasi re-identifikasi, dan (2) melakukan agregasi tambahan pada level wilayah/waktu kecil sebelum ditampilkan dalam laporan atau dashboard publik.

2.6 Izin Redistribusi melalui GitHub

Dataset **Indonesia E-Commerce Sales & Shipping 2023–2025** yang diperoleh dari Kaggle memiliki lisensi **CC BY-SA 4.0 (Creative Commons Attribution-ShareAlike 4.0 International)**. Lisensi tersebut memperbolehkan dataset untuk digunakan, dibagikan, dan didistribusikan kembali dengan tetap mencantumkan atribusi kepada pembuat dataset serta mempertahankan lisensi yang sama pada distribusi ulang.

Dalam repository GitHub kelompok, dataset dapat disertakan sebagai bagian dari dokumentasi proyek dengan mencantumkan sumber dataset, nama pembuat, judul dataset, serta tautan sumber Kaggle. Penggunaan dataset dilakukan untuk kepentingan akademik dan analisis data.

Sumber dataset: BakiTacos, *Indonesia E-Commerce Sales & Shipping 2023–2025*, Kaggle.
Lisensi: CC BY-SA 4.0.

BAB III

RINGKASAN TEORI DAN PENELITIAN TERDAHULU

3.1 Ringkasan Teori

Analisis pola penjualan dan pengiriman e-commerce umumnya berpijak pada kerangka kerja proses data mining seperti CRISP-DM (Cross-Industry Standard Process for Data Mining), yang mencakup tahap pemahaman bisnis, pemahaman data, persiapan data, pemodelan, evaluasi, hingga deployment. Kerangka ini relevan digunakan sebagai acuan tahapan proyek, mulai dari eksplorasi data (Tugas Kelompok 1) hingga pemodelan lanjutan pada tugas berikutnya.

Terkait topik pembatalan pesanan, ditemukan penelitian terdahulu yang menggunakan dataset publik yang sama (Indonesia E-Commerce Sales and Shipping 2023–2025) untuk membangun model prediksi pembatalan pesanan e-commerce menggunakan algoritme Random Forest yang dikombinasikan dengan teknik SMOTE (Synthetic Minority Over-sampling Technique) guna menangani ketidakseimbangan kelas antara pesanan selesai dan dibatalkan, dipublikasikan pada Jurnal Manajemen Akuntansi dan Ilmu Ekonomi. Temuan ini menjadi rujukan awal bahwa dataset yang dipilih memang cocok untuk pertanyaan analitik terkait prediksi pembatalan, dan bahwa penanganan kelas tidak seimbang perlu menjadi perhatian metodologis pada tahap pemodelan lanjutan.

Selain itu, kajian umum mengenai logistik last-mile dan biaya pengiriman pada e-commerce Asia Tenggara termasuk laporan sektor dari lembaga pemerintah dan riset pasar mengonfirmasi bahwa Indonesia merupakan pasar e-commerce terbesar di ASEAN dengan tantangan distribusi biaya logistik lintas wilayah kepulauan, yang relevan sebagai konteks untuk menginterpretasikan pola ongkir pada dataset ini.

3.2 Analisis Data E-Commerce

Analisis data e-commerce merupakan proses pengolahan dan interpretasi data transaksi untuk memperoleh informasi mengenai aktivitas penjualan dan perilaku transaksi. Data e-commerce dapat mencakup informasi mengenai jumlah barang, kategori produk, metode pembayaran, pilihan pengiriman, wilayah transaksi, biaya pengiriman, diskon, serta status pesanan. Analisis terhadap data tersebut dapat digunakan untuk mengetahui pola transaksi dan karakteristik pesanan dalam periode tertentu.

Dalam penelitian ini, analisis data e-commerce digunakan untuk memahami karakteristik transaksi pada dataset Indonesia E-Commerce Sales & Shipping 2023–2025. Analisis dilakukan dengan melihat beberapa aspek, seperti distribusi status pesanan, metode pembayaran, opsi pengiriman, wilayah transaksi, jumlah barang, total pembayaran, dan biaya pengiriman.

3.3 Analisis Deskriptif

Analisis deskriptif merupakan metode yang digunakan untuk memberikan gambaran umum mengenai karakteristik suatu kumpulan data melalui perhitungan statistik dan distribusi data. Analisis ini dapat digunakan untuk mengetahui jumlah, frekuensi, nilai minimum, nilai maksimum, rata-rata, serta pola distribusi dari variabel yang tersedia.

Pada dataset yang digunakan, analisis deskriptif diterapkan untuk mengetahui karakteristik transaksi e-commerce selama periode Desember 2023 hingga November 2025. Beberapa informasi yang akan dianalisis meliputi jumlah transaksi, jumlah barang, status pesanan, metode pembayaran, opsi pengiriman, distribusi transaksi berdasarkan provinsi, total pembayaran, diskon, serta biaya pengiriman. Hasil analisis deskriptif digunakan sebagai dasar untuk memahami kondisi data sebelum dilakukan analisis lebih lanjut.

3.4 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) merupakan tahap eksplorasi data yang bertujuan untuk memahami struktur, karakteristik, pola, dan kondisi suatu dataset sebelum dilakukan pemodelan. EDA dapat dilakukan melalui pemeriksaan tipe data, nilai yang hilang, data duplikat, distribusi variabel, serta hubungan antaratribut yang relevan.

Dalam penelitian ini, EDA dilakukan terhadap dataset Indonesia E-Commerce Sales & Shipping 2023–2025 untuk mengetahui kondisi awal data dan menemukan pola yang dapat digunakan dalam analisis. Tahapan EDA meliputi pemeriksaan struktur dataset, pengecekan nilai yang hilang, pemeriksaan data duplikat, pengamatan distribusi data, serta identifikasi atribut yang relevan dengan pertanyaan analitik.

3.5 Visualisasi Data

Visualisasi data merupakan metode penyajian informasi dalam bentuk grafik atau diagram untuk membantu memahami pola, perbandingan, dan distribusi data. Penggunaan visualisasi dapat mempermudah interpretasi data karena informasi yang terdapat dalam kumpulan data dapat disajikan secara lebih ringkas dan mudah dibandingkan dengan penyajian dalam bentuk tabel saja.

Pada penelitian ini, visualisasi digunakan untuk menggambarkan pola transaksi berdasarkan waktu, wilayah, status pesanan, metode pembayaran, dan opsi pengiriman. Grafik garis dapat digunakan untuk melihat perubahan jumlah transaksi dari waktu ke waktu, sedangkan grafik batang dapat digunakan untuk membandingkan jumlah transaksi berdasarkan provinsi, status pesanan, metode pembayaran, dan opsi pengiriman. Selain itu, histogram atau boxplot dapat digunakan untuk melihat distribusi total pembayaran dan biaya pengiriman.

3.6 Status dan Pembatalan Pesanan

Status pesanan merupakan informasi yang menunjukkan kondisi suatu transaksi dalam proses pemesanan hingga penyelesaian. Dalam dataset yang digunakan, terdapat berbagai status pesanan, termasuk pesanan yang selesai dan pesanan yang dibatalkan. Status tersebut dapat digunakan untuk mengetahui tingkat keberhasilan transaksi dan mengidentifikasi karakteristik pesanan yang mengalami pembatalan.

Pembatalan pesanan dapat disebabkan oleh berbagai kondisi, seperti perubahan keputusan pembeli, perubahan pesanan, pembayaran yang tidak diselesaikan, perubahan alamat pengiriman, keterlambatan pengiriman, maupun kegagalan pengiriman. Oleh karena itu, analisis terhadap status dan alasan pembatalan dapat memberikan gambaran mengenai kondisi yang berkaitan dengan tidak terselesaikannya suatu transaksi.

Pada tahap analisis lanjutan, status pesanan dapat digunakan sebagai variabel target untuk melakukan klasifikasi antara pesanan yang selesai dan pesanan yang dibatalkan. Namun, atribut alasan pembatalan perlu dipertimbangkan secara hati-hati apabila digunakan dalam pemodelan karena atribut tersebut secara langsung berkaitan dengan terjadinya pembatalan dan dapat menyebabkan kebocoran informasi (*data leakage*).

3.7 Pengiriman dan Biaya Logistik E-Commerce

Pengiriman merupakan salah satu bagian penting dalam proses transaksi e-commerce karena berkaitan dengan proses pemenuhan pesanan hingga barang diterima oleh pelanggan. Dalam dataset ini, informasi pengiriman mencakup opsi pengiriman, ongkos kirim yang dibayar oleh pembeli, estimasi potongan biaya pengiriman, dan perkiraan ongkos kirim.

Perbedaan wilayah, pilihan layanan pengiriman, berat barang, serta kebijakan biaya pengiriman dapat memengaruhi besarnya biaya logistik dalam suatu transaksi. Oleh karena itu, analisis terhadap atribut pengiriman dapat digunakan untuk melihat pola biaya pengiriman berdasarkan karakteristik transaksi dan wilayah. Informasi tersebut juga dapat digunakan sebagai salah satu pertimbangan dalam memahami hubungan antara karakteristik transaksi dengan status pesanan.

BAB IV

RENCANA METODOLOGI

4.1 Metode Deskriptif

1. Statistik ringkasan (mean, median, modus, sebaran) untuk kuantitas, berat kirim, dan ongkir.
2. Analisis tren waktu (time series) volume dan nilai pesanan bulanan.
3. Tabulasi silang status pesanan terhadap kategori produk, metode pembayaran, dan wilayah tujuan.

4.2 Rencana Visualisasi

Visualisasi data merupakan penyajian data dalam bentuk grafik atau visual agar informasi dan pola dalam data lebih mudah dipahami.

Beberapa visualisasi yang dapat digunakan dalam penelitian ini adalah:

1) Bar Chart

Bar chart digunakan untuk membandingkan nilai antar kategori. Dalam penelitian ini dapat digunakan untuk membandingkan jumlah transaksi berdasarkan provinsi, status pesanan, metode pembayaran, atau opsi pengiriman.

2) Line Chart

Line chart digunakan untuk menunjukkan perubahan suatu nilai berdasarkan waktu. Visualisasi ini dapat digunakan untuk melihat perkembangan jumlah transaksi dari bulan ke bulan.

3) Histogram

Histogram digunakan untuk melihat distribusi suatu variabel numerik, seperti total pembayaran, total diskon, atau biaya pengiriman.

4) Boxplot

Boxplot digunakan untuk melihat distribusi data dan mengidentifikasi kemungkinan *outlier*. Visualisasi ini dapat digunakan pada variabel seperti total pembayaran, jumlah barang, berat barang, dan biaya pengiriman.

Pemilihan jenis visualisasi akan disesuaikan dengan karakteristik variabel dan tujuan analisis.

4.3 Metode Lanjutan

Metode lanjutan yang direncanakan adalah **klasifikasi menggunakan algoritme Random Forest**. Metode ini digunakan untuk memprediksi status pesanan berdasarkan karakteristik transaksi, seperti jumlah barang, berat barang, metode pembayaran, opsi pengiriman, diskon, dan biaya pengiriman. Target klasifikasi terdiri dari dua kelas, yaitu **Selesai** dan **Batal**. Atribut alasan pembatalan tidak digunakan sebagai variabel prediktor karena secara langsung berkaitan dengan status pembatalan dan berpotensi menyebabkan *data leakage*.

4.4 Baseline

Baseline yang digunakan adalah **kelas mayoritas (*majority class*)**. Model baseline akan memprediksi seluruh pesanan berdasarkan status yang memiliki jumlah data paling banyak. Hasil baseline kemudian dibandingkan dengan hasil model Random Forest untuk mengetahui apakah model yang digunakan memberikan peningkatan kinerja dibandingkan prediksi sederhana.

4.5 Metrik Evaluasi

Kinerja model akan dievaluasi menggunakan **accuracy, precision, recall, F1-score, dan confusion matrix**. Penggunaan beberapa metrik diperlukan karena jumlah data pada setiap status pesanan tidak seimbang.

4.6 Jadwal dan Pembagian Tugas

A) Jadwal Pengerjaan

Minggu	Kegiatan
05 September 2026	Menentukan dataset, memahami isi dataset, dan membuat Data Card
05 September 2026	Menyusun Pendahuluan, Tinjauan Pustaka, dan pertanyaan analitik
06 September 2026	Melakukan preprocessing dan analisis deskriptif serta menentukan rencana visualisasi
06 September 2026	Menentukan metode lanjutan, baseline, metrik evaluasi, dan melakukan finalisasi laporan

B) Pembagian Tugas

No.	Anggota	Tugas
1	Keysa	Mencari dan memahami dataset serta membuat Data Card
2	Keysa	Menyusun Pendahuluan dan pertanyaan analitik
3	Zahwa	Menyusun Tinjauan Pustaka dan analisis deskriptif
4	Zahwa	Menentukan visualisasi, metode lanjutan, baseline, dan metrik evaluasi
5	Keysa & Zahwa	Menggabungkan laporan, pengecekan format, dan mengelola GitHub

BAB V
KESIMPULAN

Berdasarkan rancangan analisis yang telah disusun, dataset **Indonesia E-Commerce Sales & Shipping 2023–2025** dapat digunakan untuk menganalisis pola transaksi e-commerce, pembatalan pesanan, metode pembayaran, serta biaya pengiriman di Indonesia selama periode Desember 2023 hingga November 2025. Dataset terdiri dari data transaksi yang memuat informasi jumlah barang, berat, kategori produk, status pesanan, alasan pembatalan, metode pembayaran, lokasi tujuan, biaya pengiriman, total pembayaran, dan waktu pesanan dibuat.

Analisis deskriptif dan Exploratory Data Analysis (EDA) akan digunakan untuk melihat pola dan hubungan antarvariabel, terutama perkembangan transaksi dari waktu ke waktu, kategori produk dan metode pembayaran yang dominan, pola pembatalan pesanan, serta perbedaan biaya pengiriman berdasarkan wilayah dan nilai transaksi. Hasil visualisasi diharapkan dapat membantu menyajikan pola tersebut secara lebih mudah dipahami.

Selain analisis deskriptif, penelitian ini merencanakan penggunaan metode klasifikasi untuk memprediksi status pesanan, khususnya **Selesai** dan **Batal**, dengan menggunakan beberapa karakteristik transaksi sebagai variabel prediktor. Model akan dibandingkan dengan baseline menggunakan metrik **accuracy, precision, recall, F1-score**, dan **confusion matrix**.

Dengan demikian, penelitian ini diharapkan dapat memberikan gambaran mengenai karakteristik transaksi e-commerce Indonesia serta faktor-faktor yang berkaitan dengan pembatalan pesanan dan biaya pengiriman. Hasil analisis dapat menjadi dasar untuk memahami pola transaksi dan mendukung pengambilan keputusan dalam pengelolaan penjualan, pembayaran, pembatalan, dan logistik e-commerce.

BAB VI
DAFTAR PUSTAKA

BakiTacos. (2025). *Indonesia E-Commerce Sales & Shipping 2023–2025* [Data set]. Kaggle. https://www.kaggle.com/datasets/bakitacos/indonesia-e-commerce-sales-and-shipping-20232025

BAB VII
LAMPIRAN

URL repository GitHub : https://github.com/keysa-keysa/Tugas-Kelompok-1/tree/main