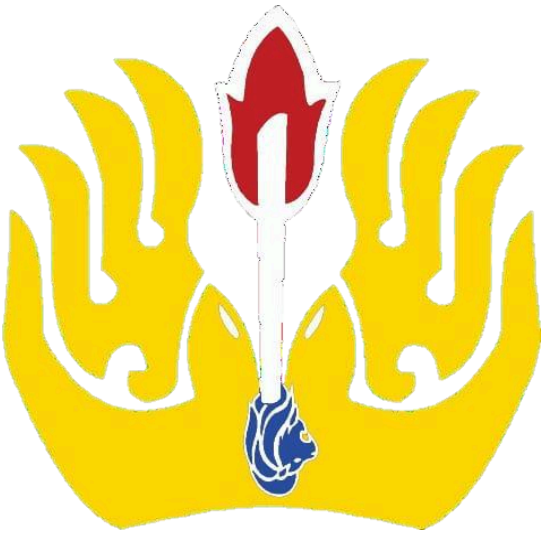
LAPORAN TUGAS 2 KELOMPOK

"Akuisisi, Kualitas Data, dan EDA
Analisis Pola Penjualan, Pembatalan Pesanan, dan Biaya Pengiriman pada E-Commerce Indonesia Periode 2023–2025"

Disusun untuk Memenuhi Tugas Mata Kuliah Pengantar Big Data

Dosen Pengampu: Nono Heryana, S.Kom., M.Kom.



Disusun oleh:

Keysa Avmalia (2410631250013)

Zahwa Lamini Arsyi Anjuni (2410631250114)

(Kelompok 5)

Kelas 5C

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS ILMU KOMPUTER

UNIVERSITAS SINGAPERBANGSA KARAWANG

TAHUN 2026

DAFTAR ISI

1. Akuisisi Data dan Penyimpanan Data Asli..... 3

2. Data yang Boleh Dibagikan..... 4

3. Kamus Data..... 4

4.1 Data kosong (null)..... 6

4.2 Data ganda..... 6

4.3 Perubahan struktur dan integrasi 24 file bulanan..... 6

4.4 Sebaran angka dan nilai ekstrem (outlier)..... 6

4.5 Label yang tidak seragam..... 7

4.6 Konsistensi logika dan kebocoran data (data leakage)..... 7

5. Cleaning, Integrasi, dan Transformasi..... 8

Hasil standardisasi status..... 9

Kolom turunan yang ditambahkan..... 9

6. Exploratory Data Analysis (EDA)..... 9

Keterbatasan..... 13

7. Revisi Hasil Tugas 1..... 13

8. Draf Bagian "Data dan Persiapan Data" untuk Artikel..... 14

9. Daftar Luaran dan Lokasi..... 14

Lampiran: Fungsi Tiap Skrip..... 15

Laporan ini berisi mengambil data, memeriksa kualitasnya, membersihkannya lewat kode, lalu menjelajahinya (EDA) untuk menjawab lima pertanyaan penelitian dari Tugas 1. Berikut ringkasannya.

Hal yang diperiksa	**Temuan**
Besar data	20.848 pesanan, 19 kolom, dari Desember 2023 sampai November 2025 (24 bulan). Satu baris = satu pesanan.
Data ganda	Tidak ada. Tidak ada baris yang sama persis dan tidak ada *order_id* yang kembar.
Data kosong	Hanya di 2 kolom. *Alasan Pembatalan* kosong 86,43% (wajar, hanya terisi kalau pesanan batal). *Waktu Pesanan Dibuat* kosong 9,50% karena dua file bulanan (Des 2024 dan Jul 2025) memang tidak punya kolom tanggal.
Pesanan batal	2.830 dari 20.598 pesanan yang berstatus Selesai atau Batal, yaitu 13,74%. Kira-kira 1 dari 7 pesanan batal.
Bahaya kebocoran data	Total Pembayaran, Ongkir Dibayar, dan Estimasi Potongan bernilai 0 di **semua** pesanan batal. Kolom-kolom ini tidak boleh dipakai untuk memprediksi pembatalan (dijelaskan di Bagian 4.6).
Metode bayar terbanyak	COD (bayar di tempat), 55,34% dari seluruh pesanan.
Wilayah terbanyak	Jawa Barat (5.910 pesanan non-batal), disusul Banten dan DKI Jakarta.
Ongkir	Pembeli tidak membayar ongkir pada 65,1% pesanan non-batal. Makin besar nilai belanja, makin kecil kemungkinan ongkir gratis (89% pada kuartil terendah, 41% pada kuartil tertinggi).

1. Akuisisi Data dan Penyimpanan Data Asli

Item	**Keterangan**
Dataset / pembuat	Indonesia E-Commerce Sales & Shipping 2023–2025 oleh BakiTacos (Kaggle)
URL	https://www.kaggle.com/datasets/bakitacos/indonesia-e-commerce-sales-and-shippin g-20232025
Lisensi	CC BY-SA 4.0
Versi	CLEAN version (Kaggle tidak mencantumkan nomor versi)
Berkas yang dipakai	all_months_clean.csv (pemisah titik-koma ;, UTF-8 dengan BOM, akhir baris CRLF)

Parameter	Unduh manual (archive.zip), tanpa filter
Tanggal akses	6 September 2026 (sama dengan Data Card Tugas 1)
Checksum SHA-256	da9594dd8444c3428fc9b0160a8a46be38d2b80ebf6ab587add29377f1db7d67
Ukuran berkas	3.865.251 byte
Jumlah baris / kolom	20.848 / 19
Rentang tanggal terisi	01 Desember 2023 – 30 November 2025

2. Data yang Boleh Dibagikan

Lisensi CC BY-SA 4.0 mengizinkan data disalin, dibagikan ulang, dan diubah, **dengan syarat** mencantumkan atribusi kepada pembuat dan memakai lisensi yang sama. Karena itu data mentah maupun data olahan boleh ada di repository GitHub, disertai berkas DATA_LICENSE.md sebagai atribusi.

Berkas	**Isi**	**Keterangan**
data/raw/all_months_clean.csv	20.848 baris, 19 kolom	Salinan asli, tidak diedit
data/raw/monthly_clean/	24 file .xlsx bulanan	Salinan asli, dipakai untuk uji integrasi
data/processed/ecom_clean.csv	20.848 baris, 35 kolom	Turunan hasil kode; tetap berlisensi CC BY-SA 4.0

Menurut penerbit, ID pesanan sudah dianonimkan dan tidak ada data pribadi pelanggan. tidak menggabungkan data ini dengan sumber lain, supaya tidak ada upaya mengenali individu.

3. Kamus Data

Kamus data menjelaskan arti tiap kolom. Tiga istilah kuncinya: **kunci** adalah *order_id* (nilainya unik tiap baris); **grain** (satuan baris) adalah 1 baris = 1 pesanan; **target** adalah *Status Pesanan* (Batal atau Selesai). Satuan Rupiah adalah asumsi karena dataset tidak menyebut mata uang secara eksplisit. Berkas lengkap: tables/kamus_data.csv dan docs/kamus_data.md.

Variabel	**Artinya**	**Tipe**	**Satuan**	**Peran**	**Kosong**
order_id	ID pesanan (anonim)	teks	-	Kunci	0%

total_qty	Jumlah barang dalam pesanan	angka	unit	Fitur	0%
total_weight_gr	Berat total pesanan	angka	gram	Fitur	0%
total_returned_qty	Jumlah barang yang dikembalikan	angka	unit	Waspada bocor	0%
Total Diskon	Total potongan harga	angka	Rupiah *	Fitur	0%
product_categories	Kategori produk (dipisah koma)	teks	-	Fitur	0%
num_product_categories	Banyaknya kategori dalam satu pesanan	angka	jumlah	Fitur	0%
Status Pesanan	Status akhir pesanan	kategori	-	**TARGET**	0%
Alasan Pembatalan	Alasan batal (kosong bila tidak batal)	kategori	-	Jangan dipakai (bocor)	86,43%
Opsi Pengiriman	Layanan kirim (45 varian, sebagian tanpa nama kurir)	kategori	-	Fitur (waspada)	0%
Metode Pembayaran	Cara pembeli membayar	kategori	-	Fitur	0%
Kota/Kabupaten	Tujuan pengiriman	kategori	-	Fitur	0%
Provinsi	Tujuan pengiriman	kategori	-	Fitur	0%
Ongkos Kirim Dibayar oleh Pembeli	Ongkir yang ditanggung pembeli	angka	Rupiah *	Waspada bocor	0%
Estimasi Potongan Biaya Pengiriman	Subsidi/potongan ongkir	angka	Rupiah *	Waspada bocor	0%
Total Pembayaran	Total yang dibayar pembeli	angka	Rupiah *	Waspada bocor	0%
Perkiraan Ongkos Kirim	Perkiraan biaya kirim sebenarnya	angka	Rupiah *	Fitur	0%
Waktu Pesanan Dibuat	Tanggal dan jam pesanan dibuat	waktu	-	Fitur waktu	9,50%

source_file	Nama file bulanan asal (memuat bulan dan tahun)	teks	-	Metadata	0%

4. Kamus Data

Profiling adalah "pemeriksaan kesehatan" data sebelum dipakai. memeriksa data kosong, data ganda, perubahan struktur antar file, nilai ekstrem, label yang tidak seragam, dan kebocoran data.

4.1 Data kosong (null)

- **Alasan Pembatalan** kosong di 18.018 baris (86,43%). Ini wajar: ke-2.830 pesanan Batal semuanya punya alasan, dan tidak ada alasan pada pesanan yang tidak batal.
- **Waktu Pesanan Dibuat** kosong di 1.980 baris (9,50%). Seluruhnya berasal dari file *DecemberSales2024* dan *JulySales2025*, yang memang tidak punya kolom tanggal.
- Kolom lainnya tidak punya nilai kosong.

4.2 Data ganda

Tidak ada baris duplikat penuh (0) dan tidak ada *order_id* ganda (0). Jadi tidak ada baris yang perlu dibuang.

4.3 Perubahan struktur dan integrasi 24 file bulanan

Data gabungan (CSV) berasal dari 24 file bulanan. mengecek apakah penggabungannya utuh dengan membandingkan jumlah baris tiap file bulanan terhadap jumlah baris per *source_file* di CSV gabungan. Hasilnya **selisih 0 di semua bulan**, total 20.848 baris di kedua sisi. Artinya tidak ada baris yang hilang atau bertambah saat penggabungan.

Satu perubahan struktur ditemukan: file *DecemberSales2024* dan *JulySales2025* hanya punya 17 kolom (tanpa Waktu Pesanan Dibuat), sedangkan 22 file lainnya punya 18 kolom. Inilah penyebab kolom tanggal kosong 9,50%. Untuk memulihkan informasi waktunya, kami menurunkan kolom **periode** (tahun-bulan) dari nama file.



Gambar 1. Jumlah pesanan per bulan (dihitung dari baris tiap file bulanan; bulan diambil dari nama file).

4.4 Sebaran angka dan nilai ekstrem (outlier)

Outlier dihitung dengan aturan IQR (nilai di atas Q3 + 1,5 × IQR dianggap ekstrem). Tidak ada nilai negatif. **Semua variabel angka miring ke kanan**: sebagian besar pesanan kecil, tetapi ada segelintir pesanan sangat besar yang menarik rata-rata ke atas. Contohnya Total Pembayaran: median Rp 21.800 tetapi rata-rata Rp 50.684 (maksimum Rp 3.403.591). Berat median hanya 500 gram (maksimum 375.000 gram) dan jumlah barang median 1 (maksimum 256).

Kolom	Min	Maks	Batas atas IQR	Outlier	% outlier	Jumlah nol
total_qty	1	256	4	2.614	12,54	0
total_weight_gr	10	375.000	3.550	2.448	11,74	0
total_returned_qty	0	70	0	157	0,75	20.691
Total Diskon	0	700.000	0	135	0,65	20.713
num_product_categories	1	11	1	1.504	7,21	0
Ongkir Dibayar Pembeli	0	584.000	7.500	4.048	19,42	14.552
Estimasi Potongan Ongkir	0	312.000	37.500	788	3,78	5.309
Total Pembayaran	0	3.403.591	83.780	2.309	11,08	2.892
Perkiraan Ongkos Kirim	1	959.200	38.000	1.815	8,71	0

4.5 Label yang tidak seragam

- **Status Pesanan** punya 11 varian teks. Status "Pesanan diterima, namun Pembeli masih dapat mengajukan pengembalian hingga …" muncul dalam 7 versi karena tanggalnya ikut tertulis di dalam teks.

- **Opsi Pengiriman** punya 45 varian; sebagian tanpa nama kurir (misalnya "Hemat Kargo" dan "Reguler (Cashless)").
- **Alasan Pembatalan** punya 18 varian, bahasa Indonesia dan Inggris bercampur.

Status mentah	**Jumlah**
Selesai	17.768
Batal	2.830
Sedang Dikirim	59
Status mentah	**Jumlah**
Telah Dikirim	30
Pesanan diterima, masih bisa retur (7 versi tanggal: 5–11 Des 2025)	161 (38+34+34+25+22+6+2)

Dari sini, target klasifikasi kami adalah **Selesai vs Batal** (20.598 pesanan). Sisanya, 250 pesanan yang masih dalam proses, tidak dipakai karena hasil akhirnya belum diketahui. Kalau model hanya menebak "Selesai" untuk semua pesanan, akurasinya sudah 86,26%; ini yang kami sebut *baseline*.

4.6 Konsistensi logika dan kebocoran data (data leakage)

Pemeriksaan	**Baris yang bermasalah**
Alasan terisi tetapi status bukan Batal	0
Status Batal tetapi alasan kosong	0
Jumlah dikembalikan lebih besar dari jumlah dibeli	0
num_product_categories tidak cocok dengan jumlah kategori di teks	0
Pesanan dengan barang dikembalikan (> 0)	157 (informasi, bukan kesalahan)
Total Pembayaran = 0	2.892 (2.830 Batal + 62 Selesai)
Perkiraan ongkir = ongkir dibayar + potongan	17.937 baris cocok

kebocoran data pada pesanan yang dibatalkan, uang belum benar-benar berpindah sehingga kolom-kolom nominal otomatis bernilai 0.

Fitur	**% nol / tanpa kurir pada pesanan Batal**	**% pada pesanan non-batal**
Total Pembayaran	100,0	0,3
Ongkos Kirim Dibayar oleh Pembeli	100,0	65,1
Estimasi Potongan Biaya Pengiriman	100,0	13,8
Perkiraan Ongkos Kirim	0,0	0,0

Total Diskon	99,2	99,4
Opsi Pengiriman tanpa nama kurir	25,4	0,0

Karena itu, untuk model prediksi nanti **mengeluarkan** Total Pembayaran, Ongkir Dibayar, Estimasi Potongan, *Alasan Pembatalan*, *total_returned_qty*, dan Opsi Pengiriman tanpa nama kurir (718 baris, hanya ada pada pesanan Batal). Sebaliknya, Perkiraan Ongkos Kirim dan Total Diskon tidak membedakan Batal dan non-batal sehingga tetap aman dipertimbangkan.

5. Cleaning, Integrasi, dan Transformasi

Skrip 04_cleaning.py membaca data mentah dan menulis data/processed/ecom_clean.csv (20.848 baris, 35 kolom). Integrasi dikerjakan oleh 02_integrasi.py, yang mencocokkan 24 file bulanan dengan CSV gabungan. **Tidak ada baris yang dihapus**, karena tidak ada duplikat maupun nilai negatif. Yang dilakukan adalah merapikan dan menambah kolom turunan. Catatan lengkap: tables/catatan_cleaning.csv dan docs/catatan_cleaning.md.

Langkah	**Baris sebelum → sesudah**	**Alasan**
Rapikan spasi di kolom teks	20.848 → 20.848	Mencegah satu kategori tercatat ganda karena spasi.
Hapus baris duplikat penuh	20.848 → 20.848	Tidak ada duplikat (0 baris).
Langkah	**Baris sebelum → sesudah**	**Alasan**
Ubah ke format tanggal + penanda *tanggal_kosong*	20.848 → 20.848	1.980 baris kosong, semuanya dari 2 file tanpa kolom tanggal.
Buat kolom periode (tahun-bulan) dari *source_file*	20.848 → 20.848	Memulihkan informasi bulan untuk baris tanpa tanggal.
Standardisasi Status Pesanan (4 kelompok)	20.848 → 20.848	11 varian teks disederhanakan; target = Selesai vs Batal.
Standardisasi Alasan Pembatalan	20.848 → 20.848	18 varian jadi 8 alasan baku + pihak pembatal (Pembeli/Sistem/Penjual).
Standardisasi Opsi Pengiriman	20.848 → 20.848	45 varian jadi 28 layanan; kurir dikelompokkan SPX, JNE, J&T, Instan/lainnya, Belum ditentukan.
Kolom bantu EDA	20.848 → 20.848	kategori_utama, ongkir_gratis, pembayaran_nol, ongkir_per_kg,

		outlier_pembayaran. Outlier hanya ditandai.

Hasil standardisasi status

Status standar	Jumlah	Dipakai untuk klasifikasi?
Selesai	17.768	Ya
Batal	2.830	Ya
Diterima (masa pengembalian)	161	Tidak
Dalam pengiriman	89	Tidak

Kolom turunan yang ditambahkan

- **periode, tahun, bulan**: dari nama file; tersedia untuk 100% baris.
- **status_final, is_batal, dipakai_klasifikasi**: label Selesai/Batal yang konsisten.
- **pembatal, alasan_baku**: siapa yang membatalkan dan alasan yang sudah dibakukan.
- **layanan_kirim, kurir**: nama layanan dan kelompok kurir.
- **kategori_utama, ongkir_gratis, pembayaran_nol, ongkir_per_kg, outlier_pembayaran, tanggal_kosong**: kolom bantu untuk EDA.

6. Exploratory Data Analysis (EDA)

Karena pesanan Batal bernilai 0 pada kolom uang, analisis nilai transaksi dan ongkir memakai pesanan non-batal saja. Sekali lagi, hasilnya berupa pola (asosiasi), bukan bukti sebab-akibat. Tabel EDA ada di tables/eda_*.csv dan grafik di figures/.

Variabel	Rata-rata	Std	Min	Median	Maks
Jumlah barang	2,6	7,8	1	1	256
Berat (gram)	2.004,5	7.106,4	10	500	375.000
Total Pembayaran (Rp)	50.683,6	144.019,3	0	21.800	3.403.591
Ongkir dibayar (Rp)	4.190,0	13.578,5	0	0	584.000
Perkiraan ongkir (Rp)	18.425,6	23.791,5	1	11.000	959.200
Total Diskon (Rp)	405,2	9.784,0	0	0	700.000

Cara membacanya: pesanan "tipikal" itu kecil. Satu barang, berat 500 gram, dibayar sekitar Rp 21.800, dan hampir tidak pernah memakai diskon (median 0). Rata-rata jauh di atas median karena ada pesanan grosir yang sangat besar.

Q1. Bagaimana perkembangan jumlah transaksi dari Desember 2023 sampai November 2025?

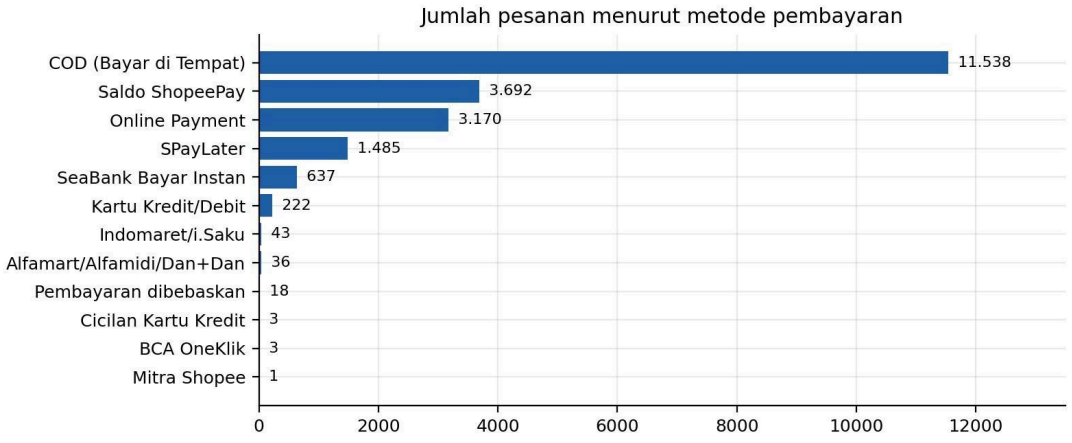
Transaksi tumbuh dari 444 pesanan (Des 2023) sampai puncaknya **1.293 pesanan pada Agustus 2024** (Gambar 1). Setelah itu naik-turun: sempat turun ke 628 pesanan pada Maret 2025, lalu pulih sampai 1.205 pada Oktober 2025. Bulan paling sepi sepanjang periode adalah Februari 2024 (389 pesanan). Dari sisi nilai, total pembayaran pesanan Selesai tertinggi terjadi pada September 2024, sebesar Rp 71,2 juta. Data tidak memuat penyebab naik-turunnya, sehingga kami tidak menebak alasannya.

Q2. Kategori produk apa yang paling banyak dipesan dan paling bernilai?

Peringkat	Berdasarkan jumlah pesanan	Berdasarkan nilai (kategori utama)
1	Celengan: 5.869 pesanan (28,15%)	Seal / Baut / Roof: Rp 276,0 juta dari 673 pesanan
2	Mangkok Sambal / Saus: 3.952 pesanan	Celengan: Rp 161,0 juta
3	Aksesoris Pintu: 2.962 pesanan	(lihat tables/eda_kategori_utama_nilai.csv)

Menarik: kategori yang paling *sering* dibeli (Celengan) bukan yang paling *bernilai* (Seal / Baut / Roof). Kategori ini jumlah pesanannya jauh lebih sedikit tetapi harga per pesanannya tinggi. Satu pesanan bisa berisi beberapa kategori, jadi jika persen tiap kategori dijumlahkan hasilnya lebih dari 100%.

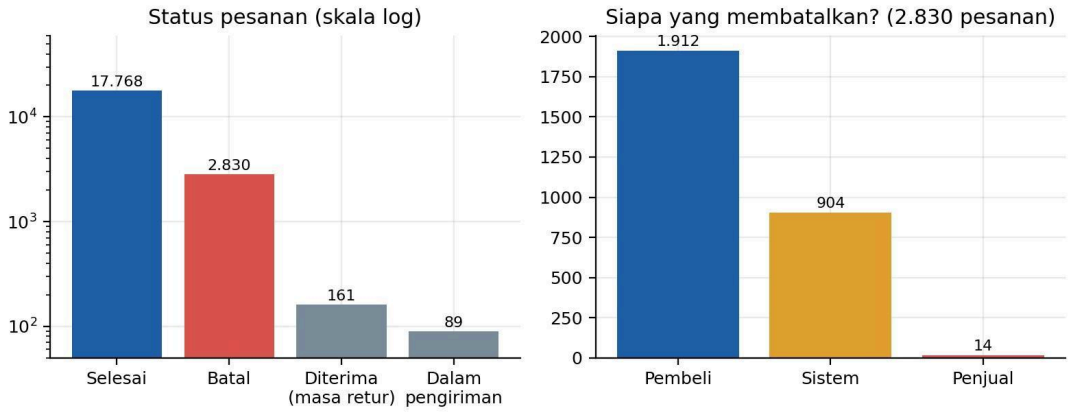
Q3. Bagaimana distribusi metode pembayaran?



Gambar 2. Jumlah pesanan menurut metode pembayaran (total 20.848).

Lebih dari separuh pesanan memakai **COD** (55,34%; 11.538 pesanan). Berikutnya Saldo ShopeePay 17,71%, Online Payment 15,21%, dan SPayLater 7,12%. SeaBank Bayar Instan sekitar 3,06% (637 pesanan), sedangkan tujuh metode lainnya masing-masing di bawah 1,1%. Dominasi COD penting dicatat karena pada COD pembayaran baru terjadi saat barang tiba.

Q4. Bagaimana pola pembatalan pesanan?



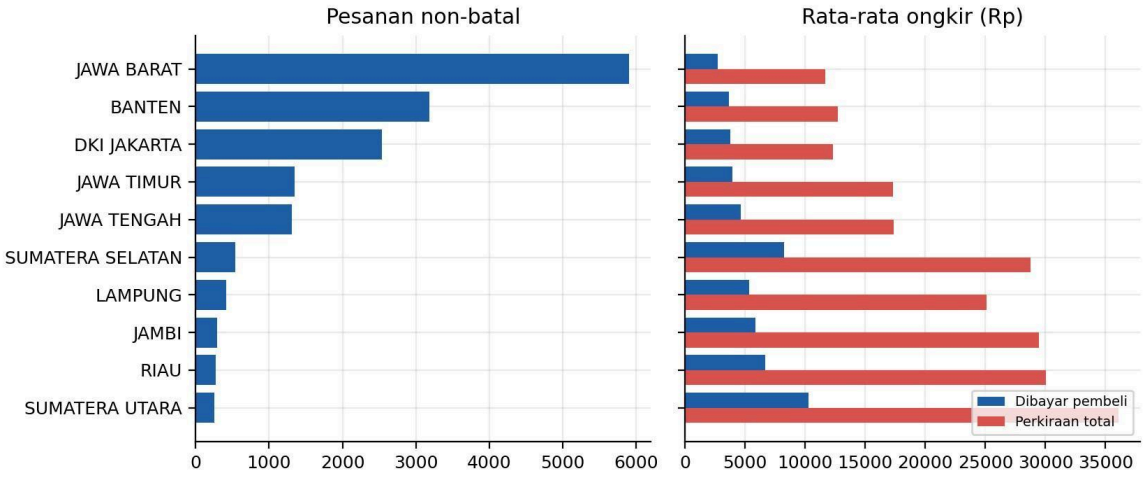
Gambar 3. Kiri: jumlah pesanan per status (skala log). Kanan: pihak yang membatalkan.

Dari 20.598 pesanan Selesai atau Batal, **13,74%** dibatalkan. Per bulan, persentase batal paling rendah 9,24% (Agustus 2025) dan paling tinggi 20,76% (Mei 2025). Dari 2.830 pembatalan, **67,6% (1.912) dilakukan pembeli**, 31,9% (904) oleh sistem, dan hanya 14 oleh penjual. Alasan terbanyaknya: lainnya/berubah pikiran (757), ubah pesanan (671), belum dibayar (447), dan ubah alamat (385).

Dilihat dari	Temuan	Catatan
Metode pembayaran	Indomaret/i.Saku 48,8% batal; Alfamart 47,2% batal; Saldo ShopeePay terendah, 8,8%.	Sampel kecil (n=43 dan n=36). Alasan terbanyak: "belum dibayar" (15 dari 21 dan 10 dari 17 pembatalan).
Kategori utama	Rak / Rak Serbaguna paling tinggi: 31,2%.	Hanya kategori dengan n ≥ 100 yang dibandingkan.
Kurir	JNE 6,0%; SPX 10,4%; J&T 14,2%.	Pesanan tanpa nama kurir dikeluarkan dari perbandingan ini karena hanya muncul pada pesanan Batal.

Kesimpulan sementara pembatalan pada metode bayar minimarket tampaknya terkait pembayaran yang tidak diselesaikan. Ini masih dugaan dari pola data belum diuji.

Q5. Bagaimana biaya pengiriman menurut wilayah dan nilai transaksi?

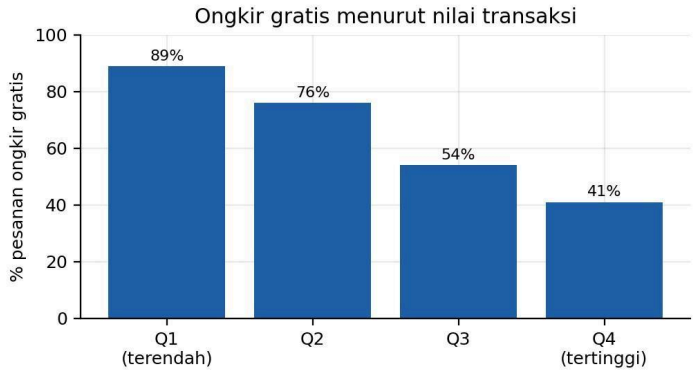


Gambar 4. Kiri: 10 provinsi dengan pesanan non-batal terbanyak. Kanan: rata-rata ongkir yang dibayar pembeli dibanding perkiraan ongkir total.

Pesanan terbanyak datang dari **Jawa Barat (5.910), Banten (3.184), dan DKI Jakarta (2.538)**. Pembeli **tidak membayar ongkir pada 65,1%** pesanan non-batal (median perkiraan ongkir Rp 10.000). Pada 99,55% pesanan, perkiraan ongkir sama dengan ongkir dibayar ditambah potongan, artinya selisih ongkir yang tidak dibayar pembeli ditutup oleh potongan/subsidi. Korelasi Spearman antara berat dan perkiraan ongkir sebesar 0,46: pesanan yang lebih berat cenderung punya ongkir lebih mahal, tetapi hubungannya sedang, bukan sempurna.

Provinsi	**Pesanan non-batal**	**Rata-rata ongkir dibayar (Rp)**	**Rata-rata perkiraan ongkir (Rp)**	**% ongkir gratis**
JAWA BARAT	5.910	2.698,8	11.649,2	72,4
BANTEN	3.184	3.671,0	12.718,1	68,9
DKI JAKARTA	2.538	3.741,8	12.316,4	69,3
JAWA TIMUR	1.348	3.933,4	17.302,3	63,8
JAWA TENGAH	1.308	4.643,7	17.376,0	67,7
SUMATERA SELATAN	537	8.221,1	28.780,9	60,5
LAMPUNG	417	5.323,2	25.080,4	62,1
JAMBI	287	5.844,9	29.439,0	58,2
RIAU	275	6.648,8	30.033,0	54,5
SUMATERA UTARA	249	10.246,6	36.077,1	35,7

Polanya jelas: provinsi di Pulau Jawa dekat pusat pengiriman, ongkirnya sekitar Rp 12–17 ribu dan lebih sering gratis (64–72%). Provinsi di Sumatera ongkirnya Rp 25–36 ribu dan pembeli lebih sering ikut membayar; di Sumatera Utara hanya 35,7% pesanan yang ongkirnya gratis.



Gambar 5. Persentase pesanan dengan ongkir gratis menurut kuartil nilai transaksi (Q1 terendah, Q4 tertinggi).

Kuartil nilai transaksi	Rata-rata ongkir dibayar (Rp)	Rata-rata perkiraan ongkir (Rp)	% ongkir gratis
Q1 (terendah)	397	9.196	89
Q2	1.263	10.439	76
Q3	4.180	15.070	54
Q4 (tertinggi)	13.551	34.497	41

Belanja kecil justru paling sering bebas ongkir (89%), sedangkan belanja besar lebih sering membayar ongkir (hanya 41% yang gratis). Kemungkinan penjelasannya terkait program gratis ongkir untuk pesanan kecil, tetapi dataset tidak memuat aturan programnya, jadi ini hanya dugaan.

Keterbatasan

- Data berasal dari satu sumber (sesuai Data Card), sehingga belum tentu mewakili seluruh e-commerce Indonesia.
- Desember 2024 dan Juli 2025 tidak punya tanggal harian; analisis waktu memakai bulan dari nama file.
- Kelas Batal dan Selesai tidak seimbang (baseline 86,26%), sehingga evaluasi model wajib memakai precision, recall, F1, dan PR-AUC, bukan hanya akurasi.
- Beberapa kelompok kecil (mis. Indomaret n=43) rawan menghasilkan persentase yang kurang stabil.
- Sebanyak 62 pesanan Selesai punya Total Pembayaran 0; penyebabnya belum bisa dijelaskan dari data.

7. Revisi Hasil Tugas 1

Sesuai perintah, berikut perbaikan atas Data Card dan Proposal Tugas 1 setelah data diperiksa lebih dalam.

Bagian	Sebelum	Sesudah (revisi)
URL Kaggle (Data Card)	Salah ketik "indonesiae-commerce"	…/indonesia-e-commerce-sales-and-shipping-202 32025
URL GitHub (Proposal)	Tugas-Kelompok-1 dan Tugas-Kelompok1 tercampur	Satu URL yang sama untuk semua rilis
Jumlah baris (Proposal)	≥ 20.000	20.848 baris, 19 kolom, 24 file bulanan
Prediktor model	Total Pembayaran dan ongkir dibayar dipertimbangkan	Dikeluarkan (bernilai 0 pada 100% pesanan Batal); begitu pula Alasan Pembatalan, Opsi Pengiriman tanpa kurir, dan total_returned_qty
Target	Status perlu didefinisikan	Batal vs Selesai (20.598 baris); 250 baris berstatus lain dikeluarkan
Bagian	**Sebelum**	**Sesudah (revisi)**
Metrik	Accuracy, precision, recall, F1	Ditambah PR-AUC; baseline accuracy 86,26%
Tanggal kosong	Penyebab belum diketahui	2 file bulanan tanpa kolom tanggal; bulan diambil dari nama file
Format berkas	Tidak disebut	CSV pemisah titik-koma (;), UTF-8 BOM
Lisensi (Data Card)	Tanda kurung tidak tertutup; redistribusi belum lengkap	CC BY-SA 4.0: boleh dibagikan ulang dengan atribusi dan lisensi yang sama
Koreksi kalimat metode bayar (laporan ini)	Tertulis "delapan metode lain di bawah 1,1%"	SeaBank Bayar Instan 3,06%; tujuh metode lain di bawah 1,1%

8. Draf Bagian "Data dan Persiapan Data" untuk Artikel

Data Penelitian ini memakai dataset publik *Indonesia E-Commerce Sales & Shipping 2023–2025* yang diterbitkan BakiTacos di Kaggle dengan lisensi CC BY-SA 4.0 (diakses 6

September 2026). Berkas yang dipakai adalah varian CLEAN, *all_months_clean.csv*, yang menggabungkan 24 file bulanan dari Desember 2023 sampai November 2025. Unit analisisnya adalah pesanan: 20.848 pesanan dengan 19 atribut (kuantitas, berat, diskon, kategori produk, status dan alasan pembatalan, opsi pengiriman, metode pembayaran, wilayah tujuan, biaya pengiriman, total pembayaran, dan waktu pesanan). Menurut penerbit, ID pesanan dianonimkan dan tidak ada data pribadi. Berkas asli disimpan tanpa perubahan di *data/raw/* dan dicatat dengan checksum SHA-256.

Kualitas data Tidak ditemukan baris duplikat maupun nilai numerik negatif. Nilai kosong hanya ada pada Alasan Pembatalan (18.018 baris, 86,43%; wajar karena hanya terisi pada pesanan batal) dan Waktu Pesanan Dibuat (1.980 baris, 9,50%; karena file Desember 2024 dan Juli 2025 tidak memuat kolom tanggal). Label status (11 varian), alasan pembatalan (18), dan opsi pengiriman (45) belum seragam. Variabel numerik sangat miring ke kanan, dengan outlier sekitar 11–12% pada total pembayaran, jumlah barang, dan berat. Ditemukan pula risiko kebocoran data: Total Pembayaran, ongkos kirim dibayar, dan estimasi potongan ongkir bernilai 0 pada seluruh pesanan batal, dan opsi pengiriman tanpa nama kurir (718 pesanan) hanya muncul pada pesanan batal.

Persiapan data Seluruh transformasi dijalankan lewat kode yang dapat diulang. Teks dirapikan, status distandardisasi menjadi empat kelompok, alasan pembatalan dibakukan menjadi delapan alasan dengan penanda pihak pembatal, dan opsi pengiriman dipetakan ke layanan dan kurir. Periode (tahun–bulan) diturunkan dari nama file sehingga tersedia untuk semua pesanan. Outlier ditandai, tidak dihapus. Untuk klasifikasi, target dibatasi pada pesanan Selesai dan Batal (20.598 pesanan: 17.768 Selesai dan 2.830 Batal; baseline kelas mayoritas 86,26%), dan fitur yang bocor dikeluarkan dari model. Hasil akhir disimpan di *data/processed/ecom_clean.csv*.

Sumber: BakiTacos (2025). Indonesia E-Commerce Sales & Shipping 2023–2025 [Data set]. Kaggle.
https://www.kaggle.com/datasets/bakitacos/indonesia-e-commerce-sales-and-shipping-20232025

9. Daftar Luaran dan Lokasi

Luaran	**Lokasi**
Laporan kualitas data dan EDA (PDF)	Dokumen ini (docs/)
Data mentah	data/raw/ (CSV + 24 file xlsx)
Data terolah	data/processed/ecom_clean.csv
Lisensi/atribusi data	DATA_LICENSE.md (CC BY-SA 4.0)

Kamus data	tables/kamus_data.csv, docs/kamus_data.md
Catatan cleaning	tables/catatan_cleaning.csv, docs/catatan_cleaning.md
Kode akuisisi	src/01_akuisisi.py
Kode integrasi	src/02_integrasi.py
Kode profiling	src/03_profiling.py
Kode cleaning dan transformasi	src/04_cleaning.py
Kode EDA	src/05_eda.py
Tabel EDA	tables/eda_*.csv, tables/profil_*.csv
Visualisasi EDA	figures/01–08 (.png)
Draf Data dan Persiapan Data	Bagian 8; docs/draf_data_dan_persiapan_data.md
Release GitHub	tag tugas-2: https://github.com/keysaavml/Tugas-Kelompok-1/releases/tag/tugas-2

Cara menjalankan ulang (dari folder src/): 01_akuisisi → 02_integrasi → 03_profiling → 04_cleaning → 05_eda. Pustaka yang dibutuhkan: pandas, matplotlib, openpyxl. Karena semua langkah lewat kode, siapa pun bisa mengulang dan mendapat hasil yang sama.

Lampiran: Fungsi Tiap Skrip

Skrip	Apa yang dikerjakan
config.py	Menyimpan lokasi berkas, pengaturan baca CSV (pemisah ; dan encoding UTF-8 BOM), dan daftar kolom.
01_akuisisi.py	Menghitung checksum SHA-256, mencatat versi, tanggal akses, dan ukuran, lalu mengunci data mentah menjadi read-only.
02_integrasi.py	Membaca 24 file bulanan, membandingkan jumlah baris dengan CSV gabungan, dan memeriksa perubahan struktur kolom antar bulan.
03_profiling.py	Membuat kamus data, lalu memeriksa nilai kosong, duplikasi, sebaran angka, outlier, inkonsistensi label, dan konsistensi logika.
04_cleaning.py	Merapikan teks, mengubah tanggal, menurunkan periode, membakukan status/alasan/opsi pengiriman, dan menambah kolom bantu; hasilnya ke data/processed/.
05_eda.py	Membuat statistik, tabel, dan grafik untuk lima pertanyaan penelitian serta pemeriksaan kebocoran data.

Kode lengkap tersimpan di folder src/ pada repository GitHub release *tugas-2*.

Nama	NIM	Kontribusi pribadi
Keysa Avmalia	2410631250013	Akuisisi, integrasi, cleaning dan transformasi, revisi Tugas 1, pengelolaan GitHub
Zahwa Lamini Arsyi Anjuni	2410631250114	Kamus data, profiling, EDA dan visualisasi, draf artikel, pengecekan akhir